#### Universidad Nacional de Córdoba

FACULTAD DE MATEMÁTICA, ASTRONOMÍA Y FÍSICA



Trabajo final del Doctorado en Ciencias de la Computación

#### Generación de expresiones referenciales: el punto de vista lógico, el más humano

Alumna: Ivana Romina Altamirano

Supervisora: Luciana Benotti

CÓRDOBA ARGENTINA Diciembre, 2013

 ${\it Gracias~Lu,~Carlos~\dots}$ 

- CLASIFICACIÓN DE BIBLIOTECA:
- Palabras Clave: expresiones referenciales, aprendizaje automático, bisimulación, evaluación.

#### RESUMEN

Se propone un algoritmo para la generación de expresiones referenciales (ERs) que adapta la aproximación de [Areces, Koller, StriegnitzAreces et al. 2008, Areces, Figueira, GorínAreces et al. 2011] para incluir sobre-especificación y probabilidades aprendidas a partir de corpus. Luego de introducir el algoritmo discutimos como las probabilidades requeridas pueden ser computadas para cualquier dominio para el cual existe un corpus de ERs y como las probabilidades pueden ser ajustadas para nuevas escenas en el dominio usando aprendizaje automático. Ejemplificamos como computar las probabilidades sobre el corpus GRE3D7 de [ViethenViethen2011] y el TUNA corpus de [Gatt, Belz, KowGatt et al. 2008]. El algoritmo resultante es capaz de generar diferentes expresiones referenciales para el mismo target con una frecuencia similar a aquella observada en el corpus. Evaluamos empíricamente el nuevo algoritmo sobre el corpus GR3D7, y mostramos que la distribución de probabilidad de las expresiones referenciales generadas por el algoritmo machean las encontradas en el corpus con alta precisión. También comparamos nuestros resultados con los resultados the [Krahmer, Theune, Viethen, HendrickxKrahmer et al. 2008], los ganadores de la competencia NLG Challenge sobre selección de atributos para generación de expresiones referenciales (ASGRE). Proveemos un análisis de error y conclusiones para ambos corpus. Se creó un nuevo corpus de ER sobre el cual se describe y se dan los resultados obtenidos, este nuevo corpus realizado sobre un entorno mucho más natural nos dá la certeza de que nuestro algoritmo se puede aplicar a sistemas de la vida real.

#### ABSTRACT

We propose an algorithm for the generation of referring expressions (REs) that adapts the approach of [Areces, Koller, StriegnitzAreces et al. 2008, Areces, Figueira, GorínAreces et al. 2011] to include overspecification and probabilities learned from corpora. After introducing the algorithm, we discuss how probabilities required as input can be computed for any given domain for which a suitable corpus of REs is available, and how the probabilities can be adjusted for new scenes in the domain using a machine learning approach. We exemplify how to compute probabilities over the GRE3D7 corpus of [ViethenViethen2011] and the TUNA corpus of [Gatt, Belz, KowGatt et al. 2008]. The resulting algorithm is able to generate different referring expressions for the same target with a frequency similar to that observed in corpora. We empirically evaluate the new algorithm over the GRE3D7 corpus, and show that the probability distribution of the generated referring expressions matches the one found in the corpus with high accuracy. We also compare our results with the results of [Krahmer, Theune, Viethen, HendrickxKrahmer et al. 2008] the winners of the NLG Challenge on Attribute Selection for Generating Referring Expressions (ASGRE). We provide error analysis and conclusion for both corpus. In this thesis we create a new corpora or REs but the new corpora is much more natural, the REs create by the algorithm for this new corpora are shown with those results we can say that our algorithm is usefull in systems of the real life.

# Índice general

1.	. Introducción	1
	1.1. Descripción del problema	. 2
	1.2. Contribuciones	. 2
	1.3. Mapa de la tesis	. 2
2.	. Selección de contenido de expresiones referenciales	3
	2.1. Generación automática de expresiones referenciales	
	2.2. Algoritmos de REG	
	2.2.1. Incremental	. 4
	2.2.2. Graph	. 4
	2.2.3. Bisimulación	. 4
	2.3. Aproximaciones empíricas a la solución de REG	. 4
	2.3.1. Corpus existente	
	2.3.2. Jette y otros trabajos empíricos	
	2.3.3. Métricas de evaluación/comparación con corpus	
	2.4. Optimalidad de expresiones referenciales	
	2.4.1. Grice	
	2.4.2. Paraboni?	
	2.4.3. Naturalidad Dale, Jette	. 4
3.	. Decisiones metodológicas de corpus y evaluación	5
	3.1. Corpus problemas de corpus existente y/o de anotación	. 6
	3.2. Comparando la salida del sistema con ER hechas por humanos	
	3.3. Problemas en la evaluación de GRE	
	3.4. Corpus seleccionados	. 6
4.	. Recolección y análisis del corpus ZOOM	7
	4.1. Características del corpus	8
	4.2. Método de recolección del corpus	
	4.3. Anotación del corpus	8
5	. Nuestra propuesta	g
υ.	5.1. Agregando probabilidades a un algoritmo existente	
	5.2. Aprendizaje automático	
	5.3. Agregando sobreespecificación	
6.	. Evaluación de nuestra propuesta	11
7.	. Conlusiones	13

VIII ÍNDICE GENERAL

## Introducción

#### 1.1. Descripción del problema

En lingüística una expresión referencial (RE) es una expresión que identifica unívocamente a un objeto de para un interlocutor, desde un conjunto de posibles distractores. Por ejemplo si nosotros queremos identificar a un cierto animal d de un conjunto de mascotas, la expresión "el perro" será ER si d es el único perro en el conjunto, y si nosotros estamos seguros que nuestro interlocutor identificará a d como un perro. Para una persona esto sería una tarea fácil de realizar, pensemos ahora como lo haría una computadora, supongamos que queremos conseguir un algoritmo que genere automáticamente esas expresiones referenciales que a la gente genera. Una propiedad es una característica de un entidad particular por ejemplo, la raza de un perro, el tener o no tener bigotes para un hombre, o el color para un objeto, cada entidad puede tener muchas propiedades, e incluso puede tener relaciones, así como las relaciones familiares, las relaciones con respecto a la posición física, etc. Para que una computadora pueda generar las ER generadas por las personas, primero debería seleccionar las propiedades y/o relaciones que se incluirán en la ER, deberá tener una base de datos conteniendo las propiedades y relaciones relevantes de la escena, podemos imaginar que una computadora podrá generar muchas más expresiones referenciales que una persona, es un desafío que direccionaremos en esta tesis generar las ER más parecidas a las que un humano generaría, o a las que la mayoría de la gente generaría, nuestra meta será imitar al humano en la generación de expresiones referenciales. Esta selección de la ER más apropiada también debe tener en cuenta al interlocutor, es natural que los humanos demos distintas ER a distintos interlocutores. En el área muchas veces se habla de optimalidad de la ER, pero con diferentes significados, para algunos una ER óptima es aquella que dice lo mínimo necesario para identificar al objeto target, para otros es la menos esfuerzo requiere del interlocutor para identificarlo Usamos generación de ER todo el tiempo en la vida real, y así los sistemas también las usan, son necesarios los algoritmos para generarlas automáticamente, las ER han sido estudiadas y tienen muchas aplicaciones prácticas desde generación de reportes meteorológicos a generación automática de resúmenes de información médica [Reiter DaleReiter Dale2000]. Muchos sistemas de GLN incluyen un módulo de GER [Mellish EvansMellish Evans2004]. Las expresiones referenciales ocupan un papel central en la comunicación, popr ejemplo sistemas que proveen advertencias en navegación aerea (White, Clark, and Moore 2010) necesitan referirse a los vuelos, en sistemas de navegación en auto [?] se necesitan generar descripciones espaciales para áreas (tomar la siguiente calle a la derecha de la iglesia), y sistemas de diálogo con un robot que ensambla piezas para la contrucción de juguetes [?] necesita referirse a las piezas (insertá el tornillo verde en el cubo)

#### 1.2. Contribuciones

- Un algoritmo para la generación de expresiones referenciales independiente de dominio.
- Un corpus de ER de un dominio mucho más natural que los existentes hasta el momento.
- Una metodología de aplicación.

#### 1.3. Mapa de la tesis

Esta tesis se divide en 7 capítulos, en el Capítulo 2 se hablará de las distintas aproximaciones a la solución de la selección automática de contenido para la generación de expresiones referenciales, daremos los algoritmos existentes en el área, las aproximaciones empíricas y hablaremos de que es lo que se propone como ER óptima. Luego en el Capítulo 3 hablaremos de los corpus existentes y la forma de aplicación de los algoritmos, como se evaluan. Dado que los corpus existentes eran de dominios muy acotados, en esta tesis se realizó un corpus de ER de un dominio mucho más natural a los existentes, y se explica en el Capítulo 4, luego en el Capítulo 5 presentamos nuestra propuesta, explicamos como nuestro algoritmo resuelve los problemas antes mencionados de nodeterminismo y sobre-especificación para luego en el Capítulo 6 daremos una evaluación general de 3 corpus analizados, realizando interesantes comparaciones con resultados obtenidos en el Challenge de GRE, y con un análisis de error, el cual nos permitirá dar interesantes conclusiones en el Capítulo 7 y líneas de trabajo futuro.

# Selección de contenido de expresiones referenciales

- 2.1. Generación automática de expresiones referenciales
- 2.2. Algoritmos de REG
- 2.2.1. Incremental
- 2.2.2. Graph
- 2.2.3. Bisimulación
- 2.3. Aproximaciones empíricas a la solución de REG
- 2.3.1. Corpus existente
- 2.3.2. Jette y otros trabajos empíricos
- 2.3.3. Métricas de evaluación/comparación con corpus
- 2.4. Optimalidad de expresiones referenciales
- 2.4.1. Grice...
- 2.4.2. Paraboni?
- 2.4.3. Naturalidad Dale, Jette

Decisiones metodológicas de corpus y evaluación

- 6
- 3.1. Corpus problemas de corpus existente y/o de anotación
- 3.2. Comparando la salida del sistema con ER hechas por humanos
- 3.3. Problemas en la evaluación de GRE
- 3.4. Corpus seleccionados

# Recolección y análisis del corpus ZOOM

#### 4.1. Características del corpus

Dominio: mapas de streetmaps. Idiomas: español, inglés y portugués.

Otras características:

- Targets singulares y plurales, los plurales tienen 2 lugares del mismo tipo.
- Imágenes con zoom.

#### 4.2. Método de recolección del corpus

La recolección se llevo a cabo mediante una página web en la que registramos 20 ER dichas por la gente. Cada persona dió 22 ER de mapas distintos, los primeros 2 mapas eran solamente para que la persona se acostumbre a usar el sistema, 11 de los cuales tenían target singular, es decir sólo 1 target y las otras 11 target plural, es decir tenían 2 targets.

#### 4.3. Anotación del corpus

# Nuestra propuesta

- 5.1. Agregando probabilidades a un algoritmo existente
- 5.2. Aprendizaje automático
- 5.3. Agregando sobreespecificación

## Evaluación de nuestra propuesta

## Conlusiones

### Bibliografía

- [Areces, Figueira, GorínAreces et al.2011] Areces, C., Figueira, S., Gorín, D. 2011. Using logic in the generation of referring expressions In Pogodalla, S. Prost, J., Proceedings of the 6th International Conference on Logical Aspects of Computational Linguistics (LACL 2011), 6736 of Lecture Notes in Computer Science, 17–32, Montpelier. Springer.
- [Areces, Koller, StriegnitzAreces et al.2008] Areces, C., Koller, A., Striegnitz, K. 2008. Referring expressions as formulas of description logic. In Proceedings of the 5th International Natural Language Generation Conference (INLG'08), 42–49, Morristown, NJ, USA. Association for Computational Linguistics.
- [Gatt, Belz, KowGatt et al.2008] Gatt, A., Belz, A., Kow, E. 2008. The tuna challenge 2008: Overview and evaluation results In Proceedings of the 5th International Conference on Natural Language Generation (INLG 2008), 198–206. Association for Computational Linguistics.
- [Krahmer, Theune, Viethen, HendrickxKrahmer et al. 2008] Krahmer, E., Theune, M., Viethen, J., Hendrickx, I. 2008. Graph: The costs of redundancy in referring expressions In 5th International Natural Language Generation Conference, INLG 2008, 227–229. The Association for Computational Linguistics.
- [Mellish EvansMellish Evans2004] Mellish, C. Evans, R. 2004. Implementation architectures for natural language generation Natural Language Engineering, 10(3/4).
- [Reiter DaleReiter Dale2000] Reiter, E. Dale, R. 2000. Building Natural Language Generation Systems. Cambridge University Press, Cambridge.
- [ViethenViethen2011] Viethen, H. A. E. 2011. The Generation of Natural Descriptions: Corpus-Based Investigations of Referring Expressions in Visual Domains. Ph.D. thesis, Macquarie University, Sydney, Australia.